BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

------- *** -------

BÁO CÁO

Môn: Phân tích và Xử lý Ảnh

Đề tài*:* A Neural Algorithm of Artistic Style

Sinh viên thực hiện:

22110038 – Trần Thành Đạt

22110073 – Đoàn Nguyễn Minh Huy

22110020 – Trần Trung Bắc

22110008 – Trần Duy An

Giảng viên hướng dẫn: *Th.S Huỳnh Thanh Sơn*

Hồ Chí Minh, 2025

Mục lục

Mục lục 1
Lời mở đầu 2
Lý do chọn đề tài 3
1. Phát biểu bài toán 4
1.1 Hiện trạng và nhu cầu 4
1.2 Các cách tiếp cận trong quá khứ 5
1.3 Áp dụng VGG19 trong Neural Style Transfer 5
2. Cơ sở lý thuyết 6
2.1. VGG19: Mạng Nơ-ron Chuyển Vị và Đặc Trưng Hình Ảnh 6
2.2 Ma trận Gram: Mô Tả Quan Hệ Giữa Các Đặc Trưng 8
3. Các bước thực hiện trong Neural Style Transfer với VGG19 9
3.1 Công thức của $Lcontent$ (Mất mát nội dung) 10
3.2 Công thức của $Lstyle$ (Mất mát phong cách) 11
3.3 Kết hợp $Lcontent$và $Lstyle$ trong hàm mất mát tổng 13
3.4 Tối ưu hóa với Gradient Descent 13
4. Kết quả của các bước thực hiện 16
4.1 Biểu diễn lại hình ảnh theo chiều sâu 16
4.2 Biểu diễn nội dung 16
4.3 Biểu diễn phong cách 18
4.4 Chuyển đổi phong cách 18
4.5 Kết quả 19
4.6 Cân bằng giữa kết hợp nội dung và phong cách 21
4.7 Ảnh hưởng của các lớp khác nhau trong Mạng Nơ-ron Tích chập 22
4.8 Khởi tạo Gradient Descent 23
4.9 Chuyển đổi phong cách cho ảnh chụp 24
5. Một số hạn chế và các vấn đề liên quan 25
6. Hướng phát triển của VGG19 trong NST 26
7. Tổng kết 27
Tài liệu tham khảo 28

Lời mở đầu

Trong một thế giới mà công nghệ phát triển với tốc độ chóng mặt, chúng ta luôn tìm kiếm những cách thức mới để thể hiện bản thân và sáng tạo. Và chuyển đổi phong cách hình ảnh chính là một trong những công cụ mạnh mẽ nhất giúp chúng ta làm điều đó. Hãy tưởng tượng bạn có một bức ảnh chụp một con đường làng bình dị vào một buổi chiều hoàng hôn. Bằng một phép màu công nghệ, bức ảnh ấy bỗng trở nên lung linh huyền ảo như một bức tranh sơn dầu của một họa sĩ impressionist. Hay một bức ảnh chân dung đơn giản được biến hóa thành một tác phẩm điêu khắc 3D sống động, như thể bước ra từ một bộ phim khoa học viễn tưởng.

Không chỉ dừng lại ở đó, công nghệ này còn mở ra những khả năng vô hạn cho các lĩnh vực khác nhau. Các nhà thiết kế thời trang có thể tạo ra những mẫu vải độc đáo, chưa từng có bằng cách kết hợp các họa tiết và màu sắc khác nhau. Các nhà làm phim có thể tạo ra những hiệu ứng hình ảnh đặc biệt, mang đến cho khán giả những trải nghiệm thị giác hoàn toàn mới. Ngay cả các nhà khoa học cũng có thể sử dụng công nghệ này để phân tích hình ảnh y tế và phát hiện ra những dấu hiệu bệnh sớm.

Với sự phát triển không ngừng của trí tuệ nhân tạo, chúng ta có thể mong đợi sẽ có nhiều ứng dụng thú vị và bất ngờ hơn nữa của công nghệ chuyển đổi phong cách hình ảnh trong tương lai. Liệu có một ngày, chúng ta có thể tạo ra cả một thế giới ảo sống động chỉ bằng một bức ảnh?

Lý do chọn đề tài

Việc lựa chọn đề tài "Chuyển đổi phong cách hình ảnh sử dụng mạng nơ-ron tích chập" xuất phát từ sự giao thoa thú vị giữa nghệ thuật và công nghệ. Trong kỷ nguyên số, khi hình ảnh trở thành một phần không thể thiếu trong cuộc sống hàng ngày, việc tạo ra những hình ảnh độc đáo, mang đậm dấu ấn cá nhân trở nên quan trọng hơn bao giờ hết. Công nghệ chuyển đổi phong cách hình ảnh, với khả năng biến đổi một bức ảnh bình thường thành một tác phẩm nghệ thuật độc đáo, không chỉ đáp ứng nhu cầu sáng tạo của con người mà còn mở ra những ứng dụng tiềm năng trong nhiều lĩnh vực.

Một trong những lý do chính khiến chúng tôi lựa chọn đề tài này là tính liên ngành của nó. Việc kết hợp kiến thức về nghệ thuật, máy học và xử lý hình ảnh tạo ra một không gian nghiên cứu vô cùng hấp dẫn. Bên cạnh đó, đề tài này cũng mang tính thời sự cao khi trí tuệ nhân tạo đang ngày càng phát triển và được ứng dụng rộng rãi trong nhiều lĩnh vực khác nhau.

Việc nghiên cứu sâu hơn về đề tài này có thể mang lại nhiều lợi ích. Đầu tiên, nó có thể thúc đẩy sự phát triển của ngành công nghiệp sáng tạo, đặc biệt là trong lĩnh vực thiết kế đồ họa, điện ảnh và quảng cáo. Thứ hai, công nghệ này có thể được ứng dụng để bảo tồn các tác phẩm nghệ thuật cổ điển, giúp chúng ta lưu giữ lại những giá trị văn hóa quý báu. Cuối cùng, việc nghiên cứu chuyển đổi phong cách hình ảnh có thể góp phần mở rộng hiểu biết của chúng ta về cách thức con người sáng tạo và cảm nhận về nghệ thuật.

1. Phát biểu bài toán

Neural Style Transfer (NST) là một bài toán trong lĩnh vực thị giác máy tính, trong đó mục tiêu là tạo ra một hình ảnh mới bằng cách kết hợp nội dung của một hình ảnh gốc (content image) với phong cách của một hình ảnh khác (style image). Kết quả là hình ảnh đầu ra (output image) sẽ giữ lại cấu trúc và chi tiết của hình ảnh nội dung, đồng thời mang các đặc điểm về màu sắc, hoa văn, và kết cấu của hình ảnh phong cách.

Cụ thể:

- Đầu vào: Hai hình ảnh:
  - I_C: hình ảnh chứa nội dung chính.
    I_S: hình ảnh chứa phong cách mong muốn.
- Đầu ra: Hình ảnh I_O, được tạo ra sao cho:
  - Nội dung của I_O giống với nội dung của I_C.
  - Phong cách của I_O giống với phong cách của I_S.

Ví dụ:

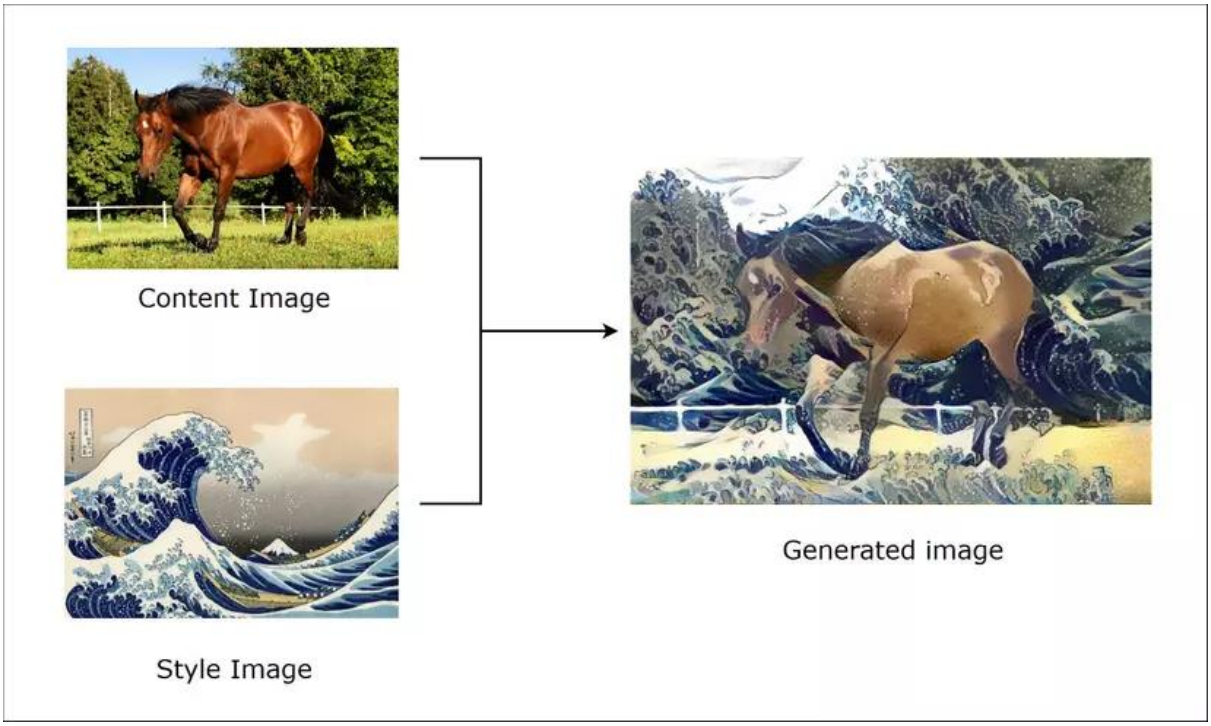

1.1 Hiện trạng và nhu cầu

1.1.1 Hiện trạng trong xử lý hình ảnh

Trước khi Neural Style Transfer xuất hiện, các kỹ thuật xử lý ảnh để áp dụng phong cách từ một hình ảnh lên hình ảnh khác chủ yếu dựa trên:

- Các bộ lọc (filters): Sử dụng các bộ lọc tuyến tính hoặc phi tuyến để điều chỉnh màu sắc, độ tương phản, và kết cấu. Tuy nhiên, phương pháp này chỉ cho ra các hiệu ứng cơ bản và không thể nắm bắt được sự phức tạp của các phong cách nghệ thuật.
- Học máy truyền thống: Các phương pháp này yêu cầu thiết kế đặc trưng thủ công (handcrafted features), nhưng không thể biểu diễn được các đặc trưng phong phú trong các phong cách nghệ thuật phức tạp.

1.1.2. Nhu cầu phát sinh

Sự phát triển của nghệ thuật kỹ thuật số và các ứng dụng sáng tạo đòi hỏi những công cụ có khả năng:

- Giữ lại nội dung chi tiết của hình ảnh ban đầu.
- Áp dụng phong cách phức tạp và tinh tế từ các tác phẩm nghệ thuật hoặc hình ảnh phong cách.
- Tạo ra kết quả một cách tự động, linh hoạt và hiệu quả.

1.2 Các cách tiếp cận trong quá khứ

1.2.1 Phương pháp dựa trên đặc trưng thủ công

Các phương pháp cũ sử dụng các đặc trưng đơn giản (ví dụ: màu sắc, histogram, hoặc gradient) để cố gắng tái tạo phong cách của một hình ảnh. Tuy nhiên, các đặc trưng thủ công này:

- Không đủ mạnh để nắm bắt các mẫu phức tạp.
- Không biểu diễn được sự tương quan không gian giữa các yếu tố trong phong cách.

1.2.2 Học sâu với mạng nơ-ron

Sự ra đời của mạng nơ-ron học sâu, đặc biệt là các kiến trúc CNN (Convolutional Neural Networks), đã mở ra hướng đi mới trong việc học và biểu diễn đặc trưng hình ảnh. Trong đó:

- Các lớp nông của mạng học được các đặc trưng cơ bản (các cạnh, đường cong, v.v.).
- Các lớp sâu học được các đặc trưng phức tạp hơn (kết cấu, hình dạng, hoặc ý nghĩa ngữ nghĩa).

1.3 Áp dụng VGG19 trong Neural Style Transfer

VGG19, một mạng nơ-ron tích chập sâu, được sử dụng để trích xuất đặc trưng nội dung và phong cách nhờ khả năng học các đặc trưng hình ảnh phong phú và tổng quát.

1.3.1 Lý do chọn VGG19

- Đã được huấn luyện trước: VGG19 được huấn luyện trên ImageNet, có khả năng biểu diễn tốt các đặc trưng phổ quát của hình ảnh.
- Phân lớp đặc trưng rõ ràng: Các lớp khác nhau trong VGG19 tương ứng với các mức độ trừu tượng khác nhau:
    - Lớp nông: Học các đặc trưng cơ bản như kết cấu, màu sắc (phù hợp để học phong cách).
    - Lớp sâu: Học các đặc trưng cấu trúc như bố cục và nội dung (phù hợp để học nội dung).
- Tính hiệu quả: Mạng không quá sâu (19 lớp), đủ đơn giản để áp dụng trong các bài toán thời gian thực mà không làm mất đi độ chính xác.

1.3.2. Quá trình trích xuất đặc trưng bằng VGG19

- Trích xuất nội dung ($L_{content}$): Nội dung được trích xuất từ một hoặc vài lớp sâu trong VGG19 (ví dụ: lớp $conv4\ 2$), vì các lớp này lưu giữ thông tin chi tiết về cấu trúc tổng thể của hình ảnh.

- Trích xuất phong cách (L_{style}): Phong cách được trích xuất từ các lớp nông hơn, nơi mô hình học được các kết cấu chi tiết như hoa văn, màu sắc, và các sự thay đổi theo không gian (ví dụ: $conv1$ 1, $conv2$ 1, $conv3$ 1, $conv4$ 1, $conv5$ 1), bằng cách tính ma trận Gram của các đặc trưng để mô tả mối quan hệ giữa chúng.

1.3.3. Tích hợp vào bài toán NST

Quá trình tối ưu hóa được thực hiện để tạo ra hình ảnh đầu ra I_O, sao cho:

- Nội dung: Đặc trưng từ lớp nội dung của I_O gần giống với I_C.
- Phong cách: Ma trận Gram từ các lớp phong cách của I_O gần giống với I_S.

Hàm mất mát tổng hợp:

$L_{total} = \alpha L_{content} + \beta L_{style}$

Với α và β là các tham số điều chỉnh mức độ ảnh hưởng của nội dung và phong cách.

2. Cơ sở lý thuyết

2.1. VGG19: Mạng Nơ-ron Chuyển Vị và Đặc Trưng Hình Ảnh

2.1.1 Khái quát về VGG19

VGG là một mạng thần kinh tích chập (CNN) có độ sâu 19 lớp. Nó được xây dựng và đào tạo bởi Karen Simonyan và Andrew Zisserman tại Đại học Oxford vào năm 2014. Bạn có thể truy cập tất cả thông tin từ bài báo của họ, Very Deep Convolutional Networks for Large-Scale Image Recognition, được xuất bản vào năm 2015. Nó được đào tạo bằng cách sử dụng hơn 1 triệu hình ảnh từ cơ sở dữ liệu ImageNet, trong đó có các ảnh màu 224×224 pixel. Đương nhiên, bạn có thể nhập vào mô hình các trọng số được huấn luyện bởi ImageNet. Điểm đặc biệt là VGG-19 có thể phân loại tới 1000 đối tượng. Hiện nay, VGG19 được sử dụng trong các bài toán phân tích hình ảnh, thường là trong các ứng dụng như nhận dạng hình ảnh, chuyển phong cách (style transfer), và trích xuất đặc trưng.

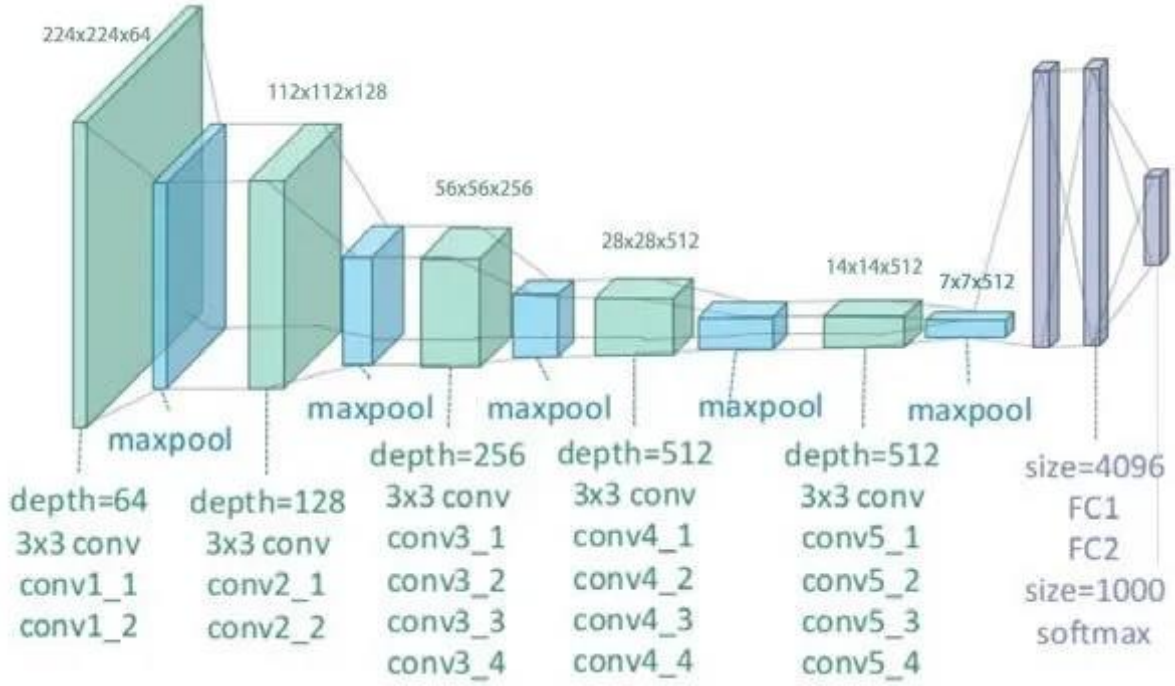

Một số thông tin về VGG19

1. **Kiến trúc:** VGG19 bao gồm 19 lớp có trọng số (weights):
- 16 lớp tích chập (convolutional layers).
- 3 lớp kết nối đầy đủ (fully connected layers).
- Các lớp phi tuyến (ReLU activation layers) và các lớp chuẩn hóa Batch Normalization để cải thiện hiệu năng.
- Các lớp pooling được sử dụng sau một số lớp tích chập để giảm kích thước không gian (spatial dimensions).

Kiến trúc chính:
- Đầu vào: Ảnh RGB kích thước 224 x 224 x 3.
- Tích chập: Bộ lọc 3 x 3 (kernel size nhỏ để tập trung chi tiết).
- Pooling: Lớp MaxPooling kích thước 2 x 2 để giảm kích thước.
- Đầu ra: Lớp Softmax với 1000 nút cho 1000 lớp phân loại.

2. **Đặc điểm chính:**
- Tăng độ chính xác: Nhờ các kernel nhỏ 3 x 3, mô hình đạt độ chính xác cao hơn so với các mô hình trước đó.
- Hệ số tham số lớn: Khoảng 143 triệu tham số, yêu cầu tài nguyên tính toán lớn.

3. **Ứng dụng:**
- Tạo ảnh (Image Generation) và xử lý ảnh (Style Transfer).
- Phân loại hình ảnh: Mô hình được huấn luyện trên bộ dữ liệu ImageNet (1 triệu ảnh với 1000 nhãn).

4. **Ưu nhược điểm:**
- Ưu điểm:
  + Đơn giản và hiệu quả: Cách thiết kế với kernel nhỏ 3 x 3 dễ hiểu và mạnh mẽ.
  + Khả năng mở rộng: Dễ áp dụng vào nhiều bài toán thị giác máy tính khác nhau.

- Nhược điểm:
  + Kích thước lớn: Nhiều tham số dẫn đến khó khăn khi triển khai trên thiết bị có tài nguyên hạn chế.
  + Tốc độ: Tốn thời gian tính toán và bộ nhớ khi xử lý ảnh lớn.

2.1.2 VGG19 trong Neural Style Transfer

VGG19, một mô hình mạng nơ-ron tích chập sâu, đóng vai trò cốt lõi trong bài toán Neural Style Transfer (NST) nhờ khả năng trích xuất đặc trưng nội dung và phong cách hiệu quả. VGG19 sở hữu 19 lớp học tham số, bao gồm 16 lớp tích chập và 3 lớp kết nối đầy đủ. Với cấu trúc tuần tự đơn giản nhưng mạnh mẽ, nó đã trở thành lựa chọn ưu tiên trong việc tái hiện nội dung và phong cách của hình ảnh trong NST.

Một trong những đặc điểm nổi bật của VGG19 là việc sử dụng các bộ lọc 3×3, giúp mô hình học được các đặc trưng quan trọng từ hình ảnh ở nhiều mức độ trừu tượng khác nhau. Các lớp

nông của VGG19 lưu giữ thông tin chi tiết về phong cách, trong khi các lớp sâu tập trung vào biểu diễn nội dung tổng thể. Đặc biệt, VGG19 hỗ trợ việc sử dụng ma trận Gram để tính toán mối quan hệ giữa các kênh đặc trưng, tạo điều kiện cho việc phân tách và tái tạo phong cách hình ảnh một cách hiệu quả.

VGG19 đã được huấn luyện trên tập dữ liệu ImageNet, một trong những tập dữ liệu lớn nhất và phong phú nhất trong thị giác máy tính. Nhờ vậy, mô hình có khả năng trích xuất đặc trưng mạnh mẽ, phù hợp với các bài toán yêu cầu khả năng nhận diện và tái tạo thông tin phức tạp như NST. Mặc dù có số lượng tham số lớn (~143 triệu), VGG19 vẫn duy trì tốc độ tính toán hợp lý, cân bằng giữa hiệu năng và thời gian xử lý.

So với các mô hình phức tạp hơn như ResNet hay Inception, VGG19 nổi bật nhờ kiến trúc đơn giản và khả năng ổn định trong tái hiện phong cách. Những mô hình hiện đại này, dù tối ưu hóa tốt hơn cho các bài toán nhận diện hình ảnh, thường gặp khó khăn trong việc tách biệt rõ ràng nội dung và phong cách do cấu trúc đa nhánh hoặc kết nối tắt. VGG19, với sự đơn giản và tính tuần tự, cho phép dễ dàng thực hiện lan truyền ngược và tối ưu hóa hình ảnh trong NST.

Tóm lại, VGG19 không chỉ là một lựa chọn kỹ thuật mà còn là tiêu chuẩn nghiên cứu trong lĩnh vực NST. Sự kết hợp giữa khả năng trích xuất đặc trưng mạnh mẽ, kiến trúc dễ hiểu và tính ứng dụng cao đã giúp VGG19 trở thành công cụ hiệu quả trong việc chuyển đổi phong cách hình ảnh, mở ra nhiều tiềm năng sáng tạo và ứng dụng thực tế trong nghệ thuật và thiết kế.

2.2 Ma trận Gram: Mô Tả Quan Hệ Giữa Các Đặc Trưng

Ma trận Gram là một công cụ mạnh mẽ được sử dụng để mô tả phong cách trong Neural Style Transfer. Ma trận Gram giúp lưu trữ mối quan hệ tương quan giữa các đặc trưng học được từ các lớp convolution của mạng nơ-ron.

2.2.1 Định nghĩa và cách tính Ma trận Gram

Ma trận Gram là một ma trận vuông được tạo thành từ các đặc trưng của các điểm trong không gian đặc trưng. Mỗi phần tử trong ma trận Gram đo lường **sự tương quan** giữa các đặc trưng tại các vị trí khác nhau trong không gian hình ảnh.

Giả sử rằng ta có một ma trận đặc trưng F với kích thước C×H×W, trong đó:

- C là số kênh (các đặc trưng) tại lớp cụ thể.
- H và W lần lượt là chiều cao và chiều rộng của các đặc trưng (sau khi hình ảnh được chia nhỏ).

Để tính ma trận Gram của một tập hợp các đặc trưng, ta thực hiện phép nhân ma trận giữa các đặc trưng:

$$Gij = \sum_{k} (F_{ik}) * (F_{jk})$$

Trong đó:

- G_{ij} là phần tử của ma trận Gram, đại diện cho sự tương quan giữa đặc trưng i và đặc trưng j.

- F_{ik} và F_{jk} là các giá trị tại các điểm k của kênh i và j.

2.2.2 Lý thuyết đằng sau Ma trận Gram

Ma trận Gram mô tả mối quan hệ giữa các đặc trưng thay vì chỉ các giá trị tại mỗi điểm cụ thể. Trong Neural Style Transfer, ta sử dụng ma trận Gram để mô tả phong cách của hình ảnh, vì phong cách không phải là các đặc trưng cụ thể ở một điểm mà là các kết cấu hoặc mẫu xuất hiện trong hình ảnh.

- Ví dụ, trong một bức tranh, các màu sắc, kết cấu và họa tiết có thể được lặp lại nhiều lần. Ma trận Gram giúp ghi nhận mối quan hệ giữa các đặc trưng trên toàn bộ không gian hình ảnh mà không quan tâm đến vị trí cụ thể của chúng.

2.2.3 Tại sao Ma trận Gram lại quan trọng trong Style Transfer?

Trong Neural Style Transfer, ta muốn học được các kết cấu và phong cách từ hình ảnh phong cách và chuyển chúng vào hình ảnh đầu ra. Để làm điều này, ma trận Gram được sử dụng để tính toán sự tương đồng giữa các đặc trưng của hình ảnh phong cách và hình ảnh đầu ra.

- Phong cách của hình ảnh phong cách được mô tả bằng các ma trận Gram của hình ảnh phong cách tại các lớp nông của mạng VGG19.
- Phong cách của hình ảnh đầu ra được mô tả bằng các ma trận Gram của hình ảnh đầu ra tại các lớp tương ứng.

Khi tối ưu hóa hình ảnh đầu ra, ta sẽ cố gắng làm cho ma trận Gram của hình ảnh đầu ra càng giống với ma trận Gram của hình ảnh phong cách càng tốt. Điều này giúp hình ảnh đầu ra học được phong cách của hình ảnh phong cách mà không làm mất đi các đặc trưng quan trọng.

3. Các bước thực hiện trong Neural Style Transfer với VGG19

Bước 1: Trích xuất đặc trưng

- Hình ảnh nội dung: Nội dung của hình ảnh được trích xuất từ các lớp sâu của VGG19. Các lớp sâu này giữ lại các đặc trưng tổng thể, ví dụ như hình dáng và cấu trúc của các đối tượng trong hình ảnh. Mạng học cách "hiểu" bức ảnh qua các đặc trưng này.
    - Ví dụ: Nếu hình ảnh nội dung là một bức chân dung, VGG19 sẽ xác định các đặc điểm như hình dạng khuôn mặt, các chi tiết như mắt, mũi, và miệng.
- Hình ảnh phong cách: Phong cách của hình ảnh được trích xuất từ các lớp nông của VGG19. Các lớp nông giúp mạng nhận diện các đặc trưng về kết cấu và màu sắc, chẳng hạn như các mẫu họa tiết hay cách sử dụng màu sắc trong một bức tranh.
    - Ví dụ: Nếu hình ảnh phong cách là một bức tranh sơn dầu, các lớp này sẽ học được các chi tiết như cách sử dụng màu sắc, các đường nét chấm phá, hay kết cấu của những nét vẽ.

Bước 2: Tính toán mất mát (Loss function)

Để đảm bảo rằng hình ảnh đầu ra không chỉ giữ lại nội dung từ hình ảnh gốc mà còn mang phong cách từ hình ảnh phong cách, chúng ta tính toán một hàm mất mát (loss function). Hàm mất mát này bao gồm hai phần chính:

- Mất mát nội dung (Content loss): Đây là sự khác biệt giữa các đặc trưng nội dung của hình ảnh tạo ra và hình ảnh nội dung gốc. Mất mát này đo lường mức độ mà hình ảnh tạo ra giữ lại cấu trúc nội dung của hình ảnh gốc.
    - Ví dụ: Nếu hình ảnh nội dung là một bức chân dung, mất mát nội dung sẽ tính toán sự khác biệt giữa vị trí các đặc trưng khuôn mặt trong hình ảnh gốc và hình ảnh tạo ra.
- Mất mát phong cách (Style loss): Mất mát phong cách đo lường sự khác biệt giữa các đặc trưng phong cách của hình ảnh tạo ra và hình ảnh phong cách. Cách phổ biến để đo lường phong cách là sử dụng ma trận Gram matrix. Ma trận Gram thể hiện mối quan hệ giữa các đặc trưng trong ảnh, ví dụ như mối quan hệ giữa các màu sắc hay các kết cấu trong hình ảnh phong cách.
    - Ma trận Gram tính toán sự tương quan giữa các đặc trưng tại các điểm khác nhau trong hình ảnh. Mất mát phong cách sẽ tính toán sự khác biệt giữa các ma trận Gram của hình ảnh tạo ra và hình ảnh phong cách.
    - Ví dụ: Nếu hình ảnh phong cách là một bức tranh theo phong cách vẽ tranh sơn dầu, ma trận Gram sẽ giúp xác định các mẫu màu sắc hoặc kết cấu của các nét vẽ trong bức tranh đó.

Bước 3: Tối ưu hóa và cập nhật hình ảnh

Sau khi tính toán được mất mát nội dung và phong cách, bước tiếp theo là tối ưu hóa hình ảnh đầu ra sao cho giá trị của hàm mất mát tổng (bao gồm cả mất mát nội dung và phong cách) được giảm thiểu.

- Gradient Descent: Để giảm thiểu hàm mất mát, ta sử dụng phương pháp tối ưu hóa Gradient Descent. Điều này có nghĩa là chúng ta sẽ tính toán đạo hàm của hàm mất mát đối với các pixel trong hình ảnh đầu ra và điều chỉnh các giá trị pixel để làm giảm mất mát.
- Quá trình này được lặp lại nhiều lần cho đến khi giá trị của hàm mất mát ổn định và đạt được mức thấp nhất có thể.

Bước 4: Kết quả cuối cùng

Sau khi hoàn tất quá trình tối ưu hóa, hình ảnh đầu ra sẽ là một hình ảnh mới mang đặc trưng nội dung của hình ảnh nội dung nhưng lại có phong cách của hình ảnh phong cách. Hình ảnh này không chỉ giữ lại các chi tiết quan trọng của hình ảnh gốc mà còn thể hiện được phong cách nghệ thuật độc đáo từ hình ảnh phong cách.

3.1 Công thức của $L_{content}$ (Mất mát nội dung)

$L_{content}$ đo lường sự khác biệt giữa đặc trưng nội dung của hình ảnh đầu ra và đặc trưng nội dung của hình ảnh gốc. Công thức này phụ thuộc vào tính năng mà VGG19 trích xuất từ các lớp sâu của mạng.

Cách xây dựng công thức:

- Công thức $L_{content}$ dựa trên sự khác biệt giữa các đặc trưng không gian ở các lớp sâu của mạng VGG19.
- F^l và P^l lần lượt là các ma trận đặc trưng tại lớp l của hình ảnh đầu ra và hình ảnh nội dung.
- Sự khác biệt giữa hai ma trận này là sự khác biệt giữa cấu trúc nội dung của hình ảnh đầu ra và hình ảnh gốc.

Công thức:

$$L_{content} = \frac{1}{2}\sum_{i,j}\left(F_{ij}^{l} - P_{ij}^{l}\right)^2$$

Trong đó:

- F^l là ma trận đặc trưng của hình ảnh đầu ra tại lớp l.
- P^l là ma trận đặc trưng của hình ảnh nội dung tại lớp l.
- i, j là chỉ số của các phần tử trong ma trận đặc trưng.
- Lớp l ở đây có thể là các lớp sâu trong mạng VGG19, nơi mạng học được các đặc trưng tổng quát và cấu trúc của hình ảnh.

Giải thích lý thuyết:

Mất mát nội dung tính toán sự khác biệt giữa đặc trưng nội dung của hình ảnh đầu ra và của hình ảnh gốc. Mục tiêu là giữ lại cấu trúc của đối tượng trong hình ảnh, ví dụ như các hình dáng của vật thể, vị trí và mối quan hệ giữa các đối tượng. Khi $L_{content}$đạt giá trị thấp, có nghĩa là hình ảnh đầu ra đã giữ lại được nội dung của hình ảnh gốc.

Lý do sử dụng đặc trưng từ các lớp sâu trong VGG19:

VGG19 là một mạng nơ-ron có cấu trúc nhiều lớp, trong đó các lớp gần đầu vào học được các đặc trưng cơ bản như cạnh, màu sắc và kết cấu. Các lớp càng sâu, chúng càng học được các đặc trưng phức tạp hơn như hình dáng, cấu trúc đối tượng và các mô hình phức tạp trong hình ảnh.

Nội dung của hình ảnh không chỉ đơn giản là các pixel mà là các cấu trúc phức tạp, sự sắp xếp của các đối tượng trong không gian. Để đo lường sự tương đồng giữa nội dung của hai hình ảnh, chúng ta cần phải tính toán sự khác biệt giữa các đặc trưng không gian của hình ảnh nội dung và hình ảnh đầu ra. Những đặc trưng này có thể được trích xuất từ các lớp sâu trong VGG19, nơi mà các đặc trưng hình ảnh đã được mã hóa dưới dạng các biểu diễn tổng quát và trừu tượng.

Tại sao không phải công thức khác?

- Việc sử dụng sự khác biệt giữa các đặc trưng ở các lớp sâu là một cách hiệu quả để giữ lại các cấu trúc nội dung của hình ảnh. Việc tính toán trực tiếp sự khác biệt giữa các pixel (giống như trong các kỹ thuật tối ưu hóa hình ảnh truyền thống) sẽ không giúp giữ lại cấu trúc đối tượng và sẽ làm hình ảnh mất đi các đặc trưng quan trọng.
- Do đó, việc sử dụng đặc trưng học được từ các lớp sâu trong mạng VGG19 giúp việc giữ lại nội dung trở nên hợp lý hơn, vì các lớp này đã học được các biểu diễn trừu tượng của hình ảnh.

3.2 Công thức của L_{style} (Mất mát phong cách)

L_{style} đo lường sự khác biệt giữa phong cách của hình ảnh đầu ra và phong cách của hình ảnh gốc. Phong cách được định nghĩa thông qua các ma trận Gram của các đặc trưng trong các lớp của mạng VGG19.

Cách xây dựng công thức:

- Công thức L_{style} tính toán sự khác biệt giữa ma trận Gram của hình ảnh đầu ra và ma trận Gram của hình ảnh phong cách.
- Ma trận Gram được tính từ các đặc trưng của mạng VGG19 tại các lớp khác nhau. Việc sử dụng các lớp nông của VGG19 giúp mô hình học được các kết cấu phong cách như màu sắc, vân (pattern), và các đặc điểm bề mặt trong hình ảnh phong cách.

Công thức:

$$L_{style} = \sum_{l} w_l \cdot \frac{1}{4{N_l}^2{M_l}^2}\left(\sum_{i,j}\left(G_{ij}^l - A_{ij}^l\right)^2\right)$$

Trong đó:

- G^l là ma trận Gram của hình ảnh đầu ra tại lớp l. ($G^l = F^l(F^l)^T$)
- A^l là ma trận Gram của hình ảnh phong cách tại lớp l. ($A^l = P^l(P^l)^T$)
- N_l là số lượng đặc trưng ở lớp l (tương ứng với số lượng kênh của ảnh).
- M_l là số lượng phần tử trong một bộ lọc (chiều cao × chiều rộng).
- w_l là trọng số của từng lớp.

Giải thích lý thuyết:

Công thức $\boldsymbol{L_{style}}$ được thiết kế để đo lường sự khác biệt giữa phong cách của hình ảnh đầu ra và phong cách của hình ảnh phong cách. Phong cách của một bức tranh không thể chỉ đơn giản là các pixel màu sắc, mà là sự kết hợp của các yếu tố như màu sắc, kết cấu, hình khối, và sự phân bố của các đặc trưng trong không gian.

Mục tiêu của công thức là làm cho hình ảnh đầu ra có phong cách (kết cấu, màu sắc, bố cục) tương tự với hình ảnh phong cách. Khi L_{style} đạt giá trị thấp, có nghĩa là hình ảnh đầu ra đã học được phong cách của hình ảnh phong cách.

Lý do sử dụng ma trận Gram:

Phong cách có thể được mô tả thông qua các **mối quan hệ giữa các đặc trưng** (ví dụ: các mối quan hệ không gian và màu sắc giữa các điểm trong hình ảnh). Các ma trận **Gram** là một cách để mô tả mối quan hệ này. Ma trận Gram của một tập hợp đặc trưng là một ma trận đối xứng, trong đó mỗi phần tử đo lường sự tương quan giữa các đặc trưng khác nhau. Điều này giúp mô tả **tính chất tương đối** giữa các đặc trưng trong hình ảnh.

Tại sao ma trận Gram lại phù hợp?

- **Ma trận Gram** giúp mô tả các kết cấu và phong cách trong một cách tổng quát hơn thay vì chỉ dựa vào các giá trị pixel hoặc các đặc trưng cụ thể ở mỗi điểm trong ảnh.
- Các đặc trưng của phong cách không cần phải ở vị trí cụ thể trong không gian hình ảnh (vì phong cách có thể lan tỏa và thay đổi khắp ảnh), mà là sự tương quan giữa các đặc trưng ở các vị trí khác nhau. Điều này khiến ma trận Gram trở thành một công cụ mạnh mẽ để mô tả phong cách.

Tại sao không phải công thức khác?

- Việc sử dụng ma trận Gram thay vì tính toán sự khác biệt giữa các pixel hay các đặc trưng đơn giản là vì phong cách không thể chỉ được mô tả bởi các pixel riêng biệt mà là các kết cấu và sự tương quan giữa các đặc trưng. Ma trận Gram giúp giải quyết bài toán này bằng cách mô tả được các mối quan hệ không gian giữa các đặc trưng mà không bị ảnh hưởng bởi vị trí cụ thể của chúng.

3.3 Kết hợp $L_{content}$ và L_{style} trong hàm mất mát tổng

Công thức của $L_{content}$ và L_{style} được sử dụng vì chúng tập trung vào hai yếu tố quan trọng trong việc chuyển giao phong cách:

- $L_{content}$ đảm bảo rằng hình ảnh đầu ra **giữ lại cấu trúc nội dung** của hình ảnh gốc. Điều này rất quan trọng, vì nếu chỉ dựa vào phong cách mà không quan tâm đến nội dung, hình ảnh đầu ra sẽ không có ý nghĩa hoặc sẽ mất đi thông tin quan trọng về đối tượng trong hình ảnh.
- L_{style} giúp hình ảnh đầu ra mang được **phong cách của hình ảnh phong cách**. Việc sử dụng ma trận Gram giúp đo lường các mối quan hệ giữa các đặc trưng hình ảnh, làm cho mô hình có thể học được các đặc điểm như màu sắc, họa tiết và kết cấu mà không cần phải sao chép từng chi tiết cụ thể.

Cuối cùng, tổng của hai hàm mất mát này được kết hợp lại để tối ưu hóa hình ảnh đầu ra. Công thức tổng là:

$$L_{total} = \alpha L_{content} + \beta L_{style}$$

Trong đó:

- α và β là các trọng số, điều chỉnh tầm quan trọng của nội dung và phong cách trong quá trình tối ưu hóa.
- Nếu α quá lớn, hình ảnh đầu ra có thể chỉ giữ lại nội dung mà không mang phong cách. Ngược lại, nếu β quá lớn, hình ảnh đầu ra sẽ chỉ giống phong cách mà không giữ được cấu trúc nội dung.

3.4 Tối ưu hóa với Gradient Descent

Gradient Descent (giảm dần độ dốc) là một thuật toán tối ưu hóa lặp được sử dụng rộng rãi trong học máy và học sâu để tìm cực tiểu của một hàm khả vi. Mục tiêu của thuật toán là điều chỉnh các tham số của mô hình sao cho hàm mất mát (loss function) đạt giá trị nhỏ nhất, tức là mô hình dự đoán chính xác nhất.

Nguyên lý hoạt động:

1. **Khởi tạo:** Bắt đầu với một giá trị ngẫu nhiên cho các tham số của mô hình.
2. **Tính gradient:** Tại mỗi bước lặp, tính gradient (đạo hàm) của hàm mất mát đối với các tham số hiện tại. Gradient này chỉ ra hướng tăng nhanh nhất của hàm mất mát.
3. **Cập nhật tham số:** Điều chỉnh các tham số theo hướng ngược lại của gradient với một bước nhảy được xác định bởi hệ số học (learning rate). Điều này giúp giảm giá trị của hàm mất mát.

4. **Lặp lại:** Lặp lại quá trình tính gradient và cập nhật tham số cho đến khi hội tụ, tức là khi sự thay đổi của hàm mất mát giữa các bước lặp rất nhỏ hoặc đạt đến số lần lặp tối đa.

3.4.1. Công thức Gradient của mất mát nội dung $L_{content}$

$$\frac{\partial L_{content}}{\partial F_{ij}^{l}} = \begin{cases} (F^l - P^l)_{ij}, & nếu\ F_{ij}^{l} > 0 \\ 0, & nếu\ F_{ij}^{l} \leq 0 \end{cases}$$

Giải thích công thức:

- F^l: Là ma trận đặc trưng trích xuất từ ảnh đầu ra I_O tại lớp l của mạng VGG19.
- P^l: Là ma trận đặc trưng trích xuất từ ảnh nội dung I_C tại lớp l của mạng.
- Gradient $\frac{\partial L_{content}}{\partial F_{ij}^{l}}$ đo độ chênh lệch giữa F^l và P^l trên từng phần tử (i, j). Điều này giúp điều chỉnh các giá trị pixel của I_O sao cho đặc trưng nội dung của nó ngày càng gần giống với ảnh nội dung I_C.

Ý nghĩa của các điều kiện:

- Khi $F_{ij}^{l} > 0$: Gradient được tính là $(F^l - P^l)_{ij}$, tức là chênh lệch trực tiếp giữa đặc trưng ảnh đầu ra và đặc trưng ảnh nội dung. Điều này đảm bảo rằng quá trình cập nhật sẽ làm giảm sự khác biệt giữa hai đặc trưng.
- Khi $F_{ij}^{l} \leq 0$: Gradient bằng 0, nghĩa là không thực hiện cập nhật tại phần tử này. Điều này giúp tránh việc cập nhật những giá trị không đóng góp tích cực vào việc giảm mất mát nội dung.

3.4.2. Công thức Gradient của mất mát phong cách L_{style}

Đạo hàm theo G^l:

$$\frac{\partial L_{style}}{\partial G^l} = \frac{1}{N_l^2 M_l^2}(G^l - A^l)$$

Tiếp theo, cần đạo hàm G^l theo F^l:

$$\frac{\partial G_{ij}^{l}}{\partial F_{mn}^{l}} = \delta_{im} F_{jn}^{l} + \delta_{jn} F_{im}^{l}$$

Từ đó, kết hợp để tính ra đạo hàm:

$$\frac{\partial L_{style}}{\partial F_{ij}^{l}} = \begin{cases} \frac{1}{N_l^2 M_l^2}((F^l)^T (G^l - A^l))_{ij}, & nếu\ F_{ij}^{l} > 0 \\ 0, & nếu\ F_{ij}^{l} \leq 0 \end{cases}$$

Giải thích công thức:

- $G^l = F^l(F^l)^T$: Ma trận Gram của ảnh đầu ra tại lớp l, thể hiện tương quan giữa các kênh đặc trưng.
- $A^l = P^l(P^l)^T$: Ma trận Gram của ảnh phong cách tại lớp l, biểu diễn phong cách cần áp dụng.
- N_l: Số lượng kênh (feature maps) tại lớp l.
- M_l: Tổng số điểm ảnh trong mỗi kênh tại lớp l.

Gradient của L_{style} đo độ chênh lệch giữa ma trận Gram G^l của ảnh đầu ra và A^lcủa ảnh phong cách.

Ý nghĩa của các điều kiện:

- Khi $F_{ij}^l > 0$: Gradient được tính dựa trên chênh lệch giữa G^l và A^l, nhằm điều chỉnh tương quan giữa các kênh trong ảnh đầu ra sao cho phù hợp với phong cách yêu cầu.
- Khi $F_{ij}^l \leq 0$: Gradient bằng 0, không cập nhật các giá trị không mang lại ý nghĩa trong việc tối ưu hóa phong cách.

3.4.3. Áp dụng Gradient trong tối ưu hóa

Sau khi tính được các gradient $\frac{\partial L_{content}}{\partial F_{ij}^l}$ và $\frac{\partial L_{style}}{\partial F_{ij}^l}$, chúng ta áp dụng các bước sau:

Bước 1: Tính Gradient tổng

Gradient tổng $\nabla_{I_O} L_{total}$ là sự kết hợp của gradient nội dung và gradient phong cách:

$$\nabla_{I_O} L_{total} = \alpha \nabla_{I_O} L_{content} + \beta \nabla_{I_O} L_{style}$$

Trong đó:

- α: Trọng số cho mất mát nội dung.
- β: Trọng số cho mất mát phong cách.

Bước 2: Cập nhật ảnh đầu ra

Gradient Descent được sử dụng để cập nhật các giá trị pixel của ảnh đầu ra I_O:

$$I_O^{k+1} = I_O^k - \eta \nabla_{I_O} L_{total}$$

Trong đó:

- η: Tốc độ học (learning rate).
- k: Số lần lặp.

Bước 3: Lặp lại quá trình

- Quá trình tính toán gradient và cập nhật hình ảnh đầu ra được lặp lại nhiều lần, cho đến khi hàm mất mát L_{total} đạt mức nhỏ nhất hoặc ổn định.

3.4.4. Tóm tắt ý nghĩa

- Gradient của $L_{content}$: Điều chỉnh các giá trị pixel sao cho đặc trưng nội dung của ảnh đầu ra gần giống với ảnh nội dung.
- Gradient của L_{style}: Điều chỉnh các giá trị pixel để tương quan giữa các kênh đặc trưng (thể hiện bởi ma trận Gram) phù hợp với phong cách yêu cầu.

- Quá trình tối ưu hóa liên tục lặp lại giúp kết hợp cả nội dung và phong cách vào ảnh đầu ra.

4. Kết quả của các bước thực hiện

4.1 Biểu diễn lại hình ảnh theo chiều sâu

Các kết quả được trình bày dưới đây được tạo ra dựa trên mạng VGG, được huấn luyện để thực hiện nhận dạng và định vị đối tượng và được mô tả chi tiết trong công trình gốc. Chúng tôi sử dụng không gian đặc trưng được cung cấp bởi phiên bản đã chuẩn hóa của 16 lớp tích chập và 5 lớp pooling của mạng VGG 19 lớp. Chúng tôi chuẩn hóa mạng bằng cách điều chỉnh trọng số sao cho kích hoạt trung bình của mỗi bộ lọc tích chập trên các hình ảnh và vị trí bằng một. Việc điều chỉnh này có thể được thực hiện cho mạng VGG mà không thay đổi đầu ra của nó, vì nó chỉ chứa các hàm kích hoạt tuyến tính chỉnh lưu và không có chuẩn hóa hoặc pooling trên các bản đồ đặc trưng. Chúng tôi không sử dụng bất kỳ lớp kết nối đầy đủ nào. Mô hình này có sẵn công khai và có thể được khám phá trong caffe-framework. Đối với việc tổng hợp hình ảnh, chúng tôi nhận thấy rằng thay thế thao tác pooling tối đa bằng pooling trung bình mang lại kết quả hấp dẫn hơn một chút, đó là lý do tại sao các hình ảnh được hiển thị được tạo ra với pooling trung bình.

4.2 Biểu diễn nội dung

Khi các CNN được huấn luyện để nhận dạng đối tượng, chúng phát triển một biểu diễn của hình ảnh làm cho thông tin về đối tượng ngày càng rõ ràng hơn dọc theo thứ bậc xử lý. Do đó, dọc theo thứ bậc xử lý của mạng, hình ảnh đầu vào được biến đổi thành các biểu diễn ngày càng nhạy cảm với nội dung thực tế của hình ảnh, nhưng trở nên tương đối không thay đổi đối với hình thức chính xác của nó. Vì vậy, *các lớp cao hơn trong mạng nắm bắt nội dung cấp cao dưới dạng các đối tượng và sự sắp xếp của chúng trong hình ảnh đầu vào nhưng không ràng buộc nhiều giá trị điểm ảnh chính xác của việc tái tạo* (Hình 1, tái tạo nội dung d, e). Ngược lại, *các tái tạo từ các lớp thấp hơn chỉ đơn giản là tái tạo lại các giá trị điểm ảnh chính xác của hình ảnh gốc* (Hình 1, tái tạo nội dung a–c). Do đó, chúng tôi gọi các phản hồi đặc trưng trong các lớp cao hơn của mạng là biểu diễn nội dung.

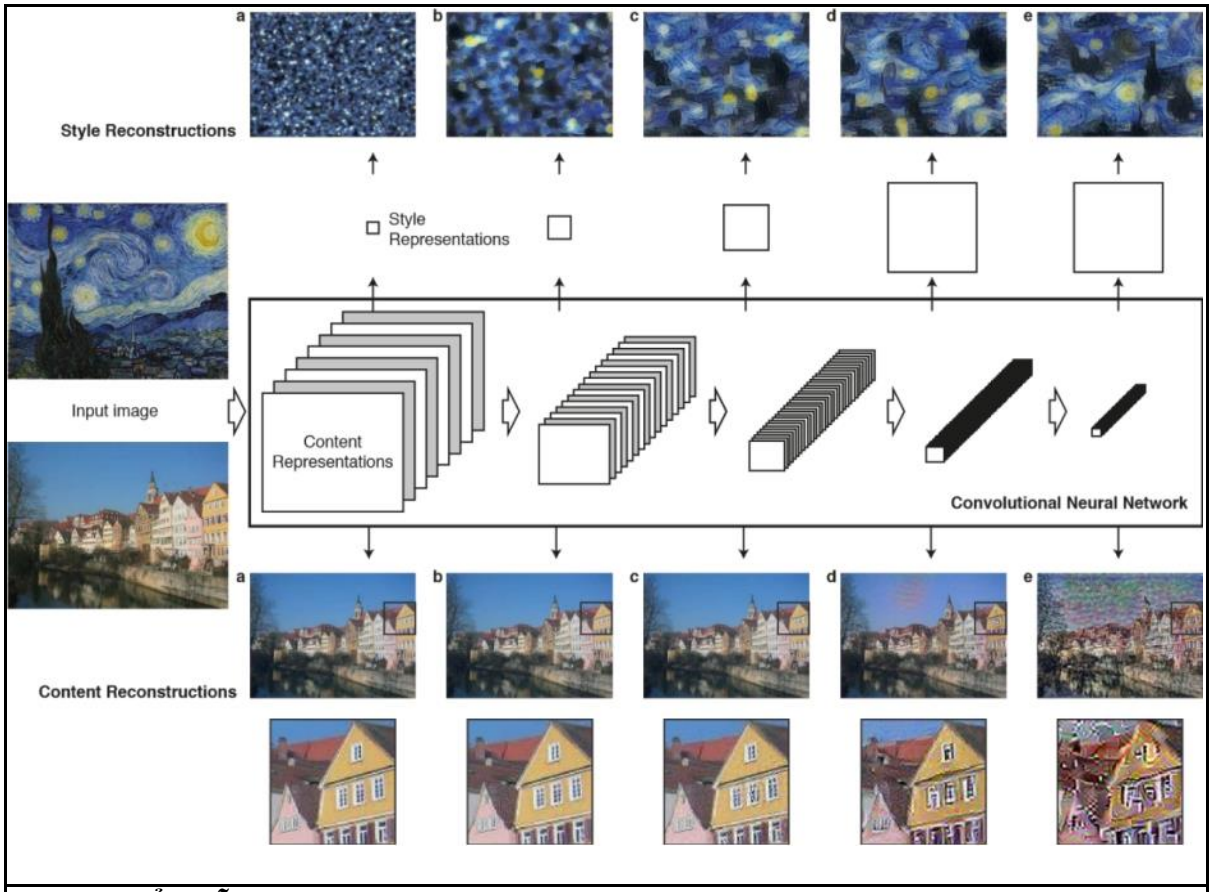

Hình 1. Biểu diễn hình ảnh trong Mạng Nơ-ron Tích chập (CNN)

Một hình ảnh đầu vào được biểu diễn dưới dạng một tập hợp các hình ảnh đã được lọc ở mỗi giai đoạn xử lý trong CNN. Khi số lượng bộ lọc khác nhau tăng lên theo thứ bậc xử lý, kích thước của các hình ảnh đã lọc giảm xuống do một số cơ chế giảm mẫu (ví dụ: max-pooling), dẫn đến giảm tổng số đơn vị trên mỗi lớp của mạng.

***Tái tạo nội dung**: Chúng ta có thể hình dung thông tin ở các giai đoạn xử lý khác nhau trong CNN bằng cách tái tạo hình ảnh đầu vào chỉ từ các phản hồi của mạng ở một lớp cụ thể. Chúng tôi tái tạo hình ảnh đầu vào từ các lớp 'conv1 2' (a), 'conv2 2' (b), 'conv3 2' (c), 'conv4 2' (d) và 'conv5 2' (e) của Mạng VGG gốc. Chúng tôi nhận thấy rằng việc tái tạo từ các lớp thấp hơn gần như hoàn hảo (a–c). Ở các lớp cao hơn của mạng, thông tin chi tiết về điểm ảnh bị mất trong khi nội dung cấp cao của hình ảnh được bảo tồn (d, e).*

***Tái tạo phong cách**: Trên các kích hoạt CNN gốc, chúng tôi sử dụng một không gian đặc trưng để nắm bắt thông tin kết cấu của một hình ảnh đầu vào. Biểu diễn phong cách tính toán các tương quan giữa các đặc trưng khác nhau trong các lớp khác nhau của CNN. Chúng tôi tái tạo phong cách của hình ảnh đầu vào từ một biểu diễn phong cách được xây dựng trên các tập hợp con khác nhau của các lớp CNN ('conv1 1' (a), 'conv1 1' và 'conv2 1' (b), 'conv1 1', 'conv2 1' và 'conv3 1' (c), 'conv1 1', 'conv2 1', 'conv3 1' và 'conv4 1' (d), 'conv1 1', 'conv2 1', 'conv3 1', 'conv4 1' và 'conv5 1' (e)). Điều này tạo ra các hình ảnh phù hợp với phong cách của một hình ảnh nhất định trên một quy mô tăng dần trong khi loại bỏ thông tin về sắp xếp toàn cục của cảnh.*

4.3 Biểu diễn phong cách

Biểu diễn phong cách sử dụng các tương quan giữa các phản hồi của bộ lọc trong các lớp khác nhau của CNN để nắm bắt thông tin kết cấu của hình ảnh. Điều này cho phép chúng ta tạo ra các hình ảnh mới kết hợp với phong cách của hình ảnh đầu vào bằng cách tối ưu hóa các ma trận Gram.

4.4 Chuyển đổi phong cách

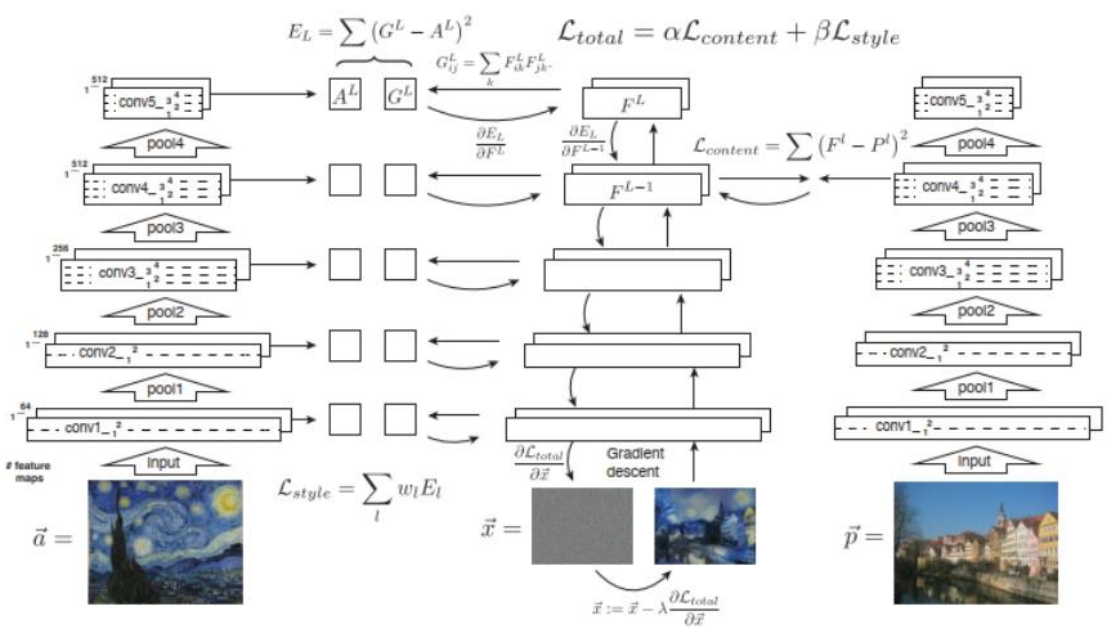

Hình 2. Thuật toán chuyển đổi phong cách hình ảnh *hoạt động như sau: Đầu tiên, các đặc trưng phong cách và nội dung được trích xuất và lưu trữ. Hình ảnh phong cách $\vec{a}$ được đưa qua mạng nơ-ron để tính toán và lưu trữ các đặc trưng phong cách A^l trên tất cả các lớp, trong khi hình ảnh nội dung $\vec{p}$ được đưa qua mạng để lưu trữ đặc trưng nội dung P^l trên một lớp. Sau đó, một hình ảnh nhiễu trắng ngẫu nhiên $\vec{x}$ được đưa qua mạng để tính toán các đặc trưng phong cách G^l và nội dung F^l. Trên mỗi lớp bao gồm trong biểu diễn phong cách, sự khác biệt bình phương trung bình giữa G^l và A^l được tính toán để cho ra hàm loss cho phong cách (L_{style}), và sự khác biệt bình phương trung bình giữa F^lvà P^l được tính toán để cho ra hàm loss nội dung ($L_{content}$). Tổng hàm loss (L_{total}) là sự kết hợp tuyến tính giữa hàm loss nội dung và phong cách, và đạo hàm của tổng hàm loss theo giá trị pixel được tính toán bằng cách sử dụng lan truyền ngược. Gradient này sau đó được sử dụng để cập nhật hình ảnh $\vec{x}$ một cách lặp đi lặp lại cho đến khi nó đồng thời khớp với các đặc trưng phong cách của hình ảnh phong cách $\vec{a}$ và các đặc trưng nội dung của hình ảnh nội dung $\vec{p}$.*

Để chuyển phong cách của một tác phẩm nghệ thuật $\vec{a}$ lên một bức ảnh $\vec{p}$, chúng tôi tổng hợp một hình ảnh mới đồng thời kết hợp với biểu diễn nội dung của $\vec{p}$ và biểu diễn phong cách của $\vec{a}$ (Hình 2). Do đó, chúng tôi đồng thời giảm thiểu khoảng cách của các biểu diễn đặc trưng của một hình ảnh nhiễu trắng từ biểu diễn nội dung của bức ảnh trong một lớp và biểu diễn phong cách của bức tranh được định nghĩa trên một số lớp của Mạng Nơ-ron Tích chập.

Hàm loss giảm thiểu:

$$L_{total}(\vec{p}, \vec{a}, \vec{x}) = \alpha L_{content}(\vec{p}, \vec{x}) + \beta L_{style}(\vec{a}, \vec{x})$$

trong đó α và β là các hệ số trọng số cho việc tái tạo nội dung và phong cách tương ứng. Gradient đối với các giá trị điểm ảnh $\frac{\partial L_{total}}{\partial \vec{x}}$ có thể được sử dụng làm đầu vào cho một chiến lược tối ưu hóa số học. Ở đây, chúng tôi sử dụng L-BFGS, mà chúng tôi thấy hoạt động tốt nhất cho việc tổng hợp hình ảnh.

Để trích xuất thông tin hình ảnh trên các tỷ lệ so sánh được, chúng tôi luôn thay đổi kích thước hình ảnh phong cách về cùng kích thước với hình ảnh nội dung trước khi tính toán các biểu diễn đặc trưng của nó. Cuối cùng, lưu ý rằng khác với công trình trước, chúng tôi không điều chỉnh kết quả tổng hợp của mình bằng các tiên nghiệm hình ảnh. Tuy nhiên, có thể lập luận rằng các đặc trưng kết cấu từ các lớp thấp hơn trong mạng hoạt động như một tiên nghiệm hình ảnh cụ thể cho hình ảnh phong cách. Ngoài ra, một số khác biệt trong việc tổng hợp hình ảnh được mong đợi do kiến trúc mạng và thuật toán tối ưu hóa khác nhau mà chúng tôi sử dụng.

Tóm lại, *quá trình chuyển đổi phong cách bao gồm việc tối ưu hóa để tạo ra một hình ảnh mới có sự kết hợp nội dung của bức ảnh đầu vào và phong cách của tác phẩm nghệ thuật*, sử dụng các kỹ thuật tối ưu hóa tiên tiến để đạt được kết quả tốt nhất.

4.5 Kết quả

Nội dung của báo cáo này là các biểu diễn nội dung và phong cách trong Mạng Nơ-ron Tích chập (CNN) có thể tách biệt rõ ràng. Điều này có nghĩa là chúng ta có thể thao tác cả hai biểu diễn này một cách độc lập để tạo ra các hình ảnh mới có ý nghĩa về mặt cảm nhận.

Để minh họa cho phát hiện này, chúng tôi tạo ra các hình ảnh kết hợp biểu diễn nội dung và phong cách từ hai hình ảnh nguồn khác nhau. Cụ thể, chúng tôi kết hợp biểu diễn nội dung của một bức ảnh chụp bờ sông Neckar ở Tübingen, Đức và các biểu diễn phong cách của một số tác phẩm nghệ thuật nổi tiếng từ các thời kỳ khác nhau của nghệ thuật (Hình 3).

Các hình ảnh được hiển thị trong Hình 3 được tổng hợp bằng cách kết hợp biểu diễn nội dung trên lớp 'conv4 2' và biểu diễn phong cách trên các lớp 'conv1 1', 'conv2 1', 'conv3 1', 'conv4 1' và 'conv5 1' (với W_L= 1/5 trong các lớp này, W_L = 0 trong tất cả các lớp khác). Tỷ lệ α/β lần lượt là $1x10^{-3}$ (Hình 3 B), $8x10^{-4}$ (Hình 3 C), $5x10^{-3}$ (Hình 3 D), hoặc $5x10^{-4}$ (Hình 3 E, F).

Điều này cho thấy khả năng tách biệt và kết hợp lại nội dung và phong cách của CNN, mở ra nhiều ứng dụng mới trong việc tạo ra các hình ảnh nghệ thuật độc đáo và sáng tạo.

Hình 3: Mô tả các hình ảnh kết hợp nội dung của một bức ảnh với phong cách của một số tác phẩm nghệ thuật nổi tiếng. *Các hình ảnh này được tạo ra bằng cách tìm một hình ảnh đồng thời khớp với biểu diễn nội dung của bức ảnh và biểu diễn phong cách của tác phẩm nghệ thuật.*

- ***A****: Bức ảnh gốc là ảnh chụp Neckarfront ở Tübingen, Đức (Được chụp bởi: Andreas Praefcke).*

Các phong cách được tạo từ các tác phẩm hội họa:

- ***B****: The Shipwreck of the Minotaur của J.M.W. Turner, 1805.*
- ***C****: The Starry Night của Vincent van Gogh, 1889.*
- ***D****: Der Schrei của Edvard Munch, 1893.*
- ***E****: Femme nue assise của Pablo Picasso, 1910.*
- ***F****: Composition VII của Wassily Kandinsky, 1913.*

4.6 Cân bằng giữa kết hợp nội dung và phong cách

Dĩ nhiên, nội dung và phong cách của hình ảnh không thể hoàn toàn tách biệt. Khi tổng hợp một hình ảnh kết hợp nội dung của một hình ảnh với phong cách của một hình ảnh khác, thường không tồn tại một hình ảnh nào hoàn toàn có thể kết hợp hoàn hảo với cả hai ràng buộc cùng một lúc. Tuy nhiên, vì hàm loss giảm thiểu trong quá trình tổng hợp hình ảnh là sự kết hợp tuyến tính giữa các hàm loss cho nội dung và phong cách, chúng tôi có thể điều chỉnh sự cân bằng để nhấn mạnh vào việc tái tạo nội dung hoặc phong cách.

Nhấn mạnh vào phong cách: Khi đặt trọng số lớn vào phong cách, kết quả là các hình ảnh kết hợp với diện mạo của tác phẩm nghệ thuật, tạo ra một phiên bản có kết cấu của nó, nhưng hầu như không hiển thị nội dung của bức ảnh với $\alpha/\beta = 5x10^{-4}$ (Hình 4, góc trên bên trái).

Nhấn mạnh vào nội dung: Khi đặt trọng số lớn vào nội dung, ta có thể dễ dàng nhận ra bức ảnh, nhưng phong cách của bức tranh không được kết hợp tốt với $\alpha/\beta = 1x10^{-1}$ (Hình 4, góc dưới bên phải).

Đối với một cặp hình ảnh nội dung và phong cách cụ thể, ta có thể điều chỉnh sự cân bằng giữa nội dung và phong cách để tạo ra các hình ảnh đẹp mắt. Điều này cho phép linh hoạt trong việc tạo ra các tác phẩm nghệ thuật số, tùy thuộc vào mức độ nhấn mạnh mà bạn muốn đặt vào nội dung hoặc phong cách của hình ảnh.

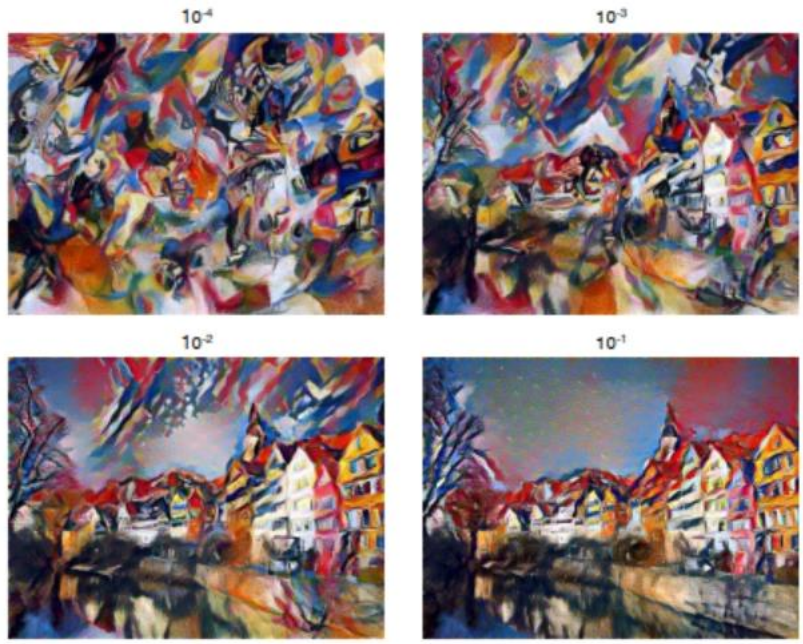

Hình 4 Việc cân nhắc tương đối giữa việc chọn nội dung và phong cách của các hình ảnh nguồn tương ứng. *Tỷ lệ α/β giữa việc nhấn mạnh nội dung hay nhấn mạnh phong cách tăng dần từ góc trên bên trái đến góc dưới bên phải. Khi nhấn mạnh cao vào phong cách, hình ảnh được tạo ra sẽ giống như một phiên bản có kết cấu của hình ảnh phong cách (góc trên bên trái). Khi nhấn mạnh cao vào nội dung, hình ảnh sẽ chỉ có ít phong cách hóa (góc dưới bên phải). Trong thực tế, người dùng có thể điều chỉnh mượt mà để cân bằng hai yếu tố này.*

4.7 Ảnh hưởng của các lớp khác nhau trong Mạng Nơ-ron Tích chập

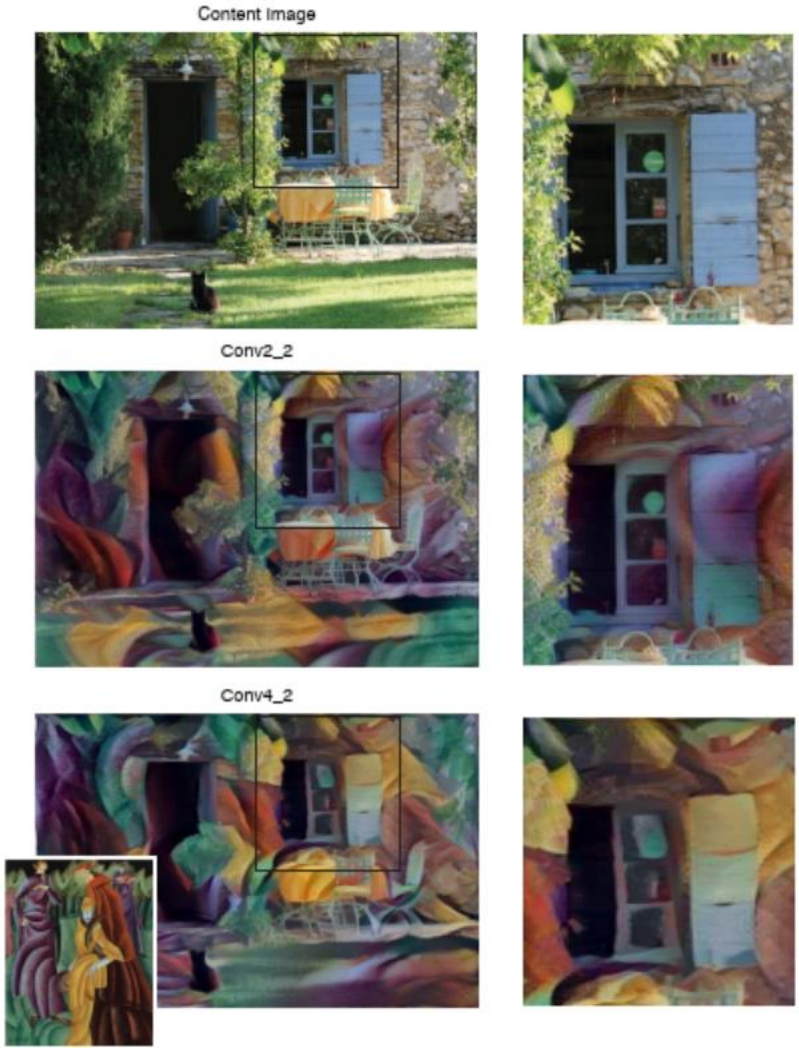

Hình 5: Tác động của việc kết hợp biểu diễn nội dung ở các lớp khác nhau của mạng nơ-ron. *Khi kết hợp nội dung ở lớp 'conv2 2', nhiều cấu trúc chi tiết của bức ảnh gốc được giữ lại và hình ảnh tổng hợp kết cấu của bức tranh phong cách được pha trộn lên bức ảnh (ở giữa). Khi kết hợp nội dung ở lớp 'conv4 2', kết cấu của bức tranh phong cách và nội dung của bức ảnh hòa quyện với nhau, khiến nội dung của bức ảnh được hiển thị theo phong cách của bức tranh (ở dưới cùng). Cả hai hình ảnh đều được tạo ra với cùng một lựa chọn tham số ($\alpha/\beta = 1\times10^{-3}$). Bức tranh được sử dụng làm hình ảnh phong cách là Jesuiten III của Lyonel Feininger, 1915, được hiển thị ở góc dưới bên trái.*

Một yếu tố quan trọng khác trong quá trình tổng hợp hình ảnh là lựa chọn các lớp để kết hợp nội dung và phong cách. Như đã đề cập ở trên, biểu diễn phong cách là một biểu diễn đa tỷ lệ bao gồm nhiều lớp của mạng nơ-ron. Số lượng và vị trí của các lớp này xác định quy mô cục bộ mà phong cách được kết hợp, dẫn đến các trải nghiệm thị giác khác nhau (Hình 1, tái tạo phong cách). Chúng tôi nhận thấy rằng để các biểu diễn phong cách lên đến các lớp cao hơn trong mạng lưới, bảo tồn cấu trúc hình ảnh cục bộ trên một quy mô ngày càng lớn, dẫn đến một trải nghiệm thị giác mượt mà và liên tục hơn. Do đó, các hình ảnh đẹp nhất thường được tạo ra bằng cách đặt biểu diễn phong cách lên đến các lớp cao trong mạng, đó là lý do tại sao

đối với tất cả các hình ảnh được hiển thị, chúng tôi để các đặc trưng phong cách trong các lớp 'conv1 1', 'conv2 1', 'conv3 1', 'conv4 1' và 'conv5 1' của mạng.

Để phân tích ảnh hưởng của việc sử dụng các lớp khác nhau để kết hợp các đặc trưng nội dung, chúng tôi trình bày một kết quả chuyển đổi phong cách thu được bằng cách cách kết hợp một bức ảnh với cùng một tác phẩm nghệ thuật và cấu hình tham số $\alpha/\beta = 1x10^{-3}$, nhưng trong một trường hợp kết hợp các đặc trưng nội dung trên lớp 'conv2 2' và trong trường hợp khác trên lớp 'conv4 2' (Hình 5). Khi đặt nội dung trên một lớp thấp hơn của mạng, thuật toán kết hợp nhiều thông tin điểm ảnh chi tiết trong bức ảnh và hình ảnh được tạo ra xuất hiện như thể kết cấu của tác phẩm nghệ thuật chỉ đơn giản là được pha trộn lên bức ảnh (Hình 5, ở giữa). Ngược lại, khi để các đặc trưng nội dung trên một lớp cao hơn của mạng lưới, thông tin điểm ảnh chi tiết của bức ảnh không bị ràng buộc mạnh mẽ và kết cấu của tác phẩm nghệ thuật và nội dung của bức ảnh được kết hợp đúng cách. Điều này có nghĩa là cấu trúc tinh tế của hình ảnh, ví dụ như các cạnh và bản đồ màu, được thay đổi sao cho phù hợp với phong cách của tác phẩm nghệ thuật trong khi vẫn hiển thị nội dung của bức ảnh (Hình 5, dưới cùng).

Tóm lại, việc lựa chọn các lớp khác nhau trong CNN để kết hợp biểu diễn nội dung và phong cách có ảnh hưởng lớn đến kết quả cuối cùng của quá trình chuyển đổi phong cách, và việc đặt các lớp cao hơn thường mang lại kết quả tốt và hình ảnh đẹp hơn.

4.8 Khởi tạo Gradient Descent

Chúng tôi đã khởi tạo tất cả các hình ảnh được hiển thị cho đến nay bằng nhiễu trắng. Tuy nhiên, cũng có thể khởi tạo quá trình tổng hợp hình ảnh bằng hình ảnh nội dung hoặc hình ảnh phong cách. Chúng tôi đã khám phá hai lựa chọn này (Hình 6 A, B): mặc dù chúng có thể làm lệch hình ảnh cuối cùng theo cấu trúc không gian của khởi tạo ban đầu, nhưng các khởi tạo khác nhau dường như không có ảnh hưởng mạnh đến kết quả của quá trình tổng hợp. Cần lưu ý rằng chỉ có khởi tạo bằng nhiễu mới cho phép tạo ra một số lượng hình ảnh mới tùy ý (Hình 6 C). Khởi tạo bằng một hình ảnh cố định luôn dẫn đến cùng một kết quả (trừ khi có sự ngẫu nhiên trong quá trình Gradient Descent).

Hình 6: Quá trình khởi tạo của gradient descent

- ***A****: Khởi tạo từ hình ảnh nội dung.*
- ***B****: Khởi tạo từ hình ảnh phong cách.*
- ***C****: Bốn mẫu hình ảnh được khởi tạo từ các hình ảnh nhiễu trắng khác nhau.*

Đối với tất cả các hình ảnh, tỷ lệ α/β đều bằng 1×10^{-3}.

4.9 Chuyển đổi phong cách cho ảnh chụp

Cho đến nay, trọng tâm của báo cáo này là chuyển đổi phong cách nghệ thuật. Tuy nhiên, thuật toán này có thể chuyển đổi phong cách giữa các hình ảnh bất kỳ. Ví dụ, chúng tôi chuyển đổi phong cách của một bức ảnh chụp New York vào ban đêm lên một hình ảnh của London vào ban ngày (Hình 7). Mặc dù quá trình chuyển đổi không được hoàn hảo, hình ảnh tổng hợp vẫn giữ được nhiều màu sắc và ánh sáng của hình ảnh phong cách và ở một mức độ nào đó hiển thị hình ảnh của London vào ban đêm.

Hình 7 minh họa quá trình chuyển đổi phong cách lấy từ ảnh chụp thực tế. *Phong cách được chuyển từ một bức ảnh chụp New York vào ban đêm sang một bức ảnh chụp London vào ban ngày. Quá trình tổng hợp hình ảnh được khởi tạo từ hình ảnh nội dung London với tỷ lệ* α/β *bằng* 1×10^{-2}.

5. Một số hạn chế và các vấn đề liên quan

Trong phần này, chúng tôi trình bày cách sử dụng các biểu diễn đặc trưng từ Mạng Nơ-ron Tích chập hiệu suất cao để chuyển đổi phong cách hình ảnh giữa các hình ảnh bất kỳ. Mặc dù chúng tôi có thể hiển thị kết quả với chất lượng cảm nhận cao, nhưng vẫn còn một số hạn chế kỹ thuật đối với thuật toán.

Có lẽ yếu tố hạn chế lớn nhất là độ phân giải của các hình ảnh được tổng hợp. Cả độ phức tạp của vấn đề tối ưu hóa và số lượng đơn vị trong Mạng Nơ-ron Tích chập đều tăng tuyến tính với số lượng pixel. Do đó, tốc độ của quy trình tổng hợp phụ thuộc nhiều vào độ phân giải hình ảnh. Các hình ảnh được trình bày trong bài báo này được tổng hợp ở độ phân giải khoảng 512×512 pixel và quy trình tổng hợp có thể mất đến một giờ trên GPU Nvidia K40 (tùy thuộc vào kích thước hình ảnh chính xác và tiêu chí dừng cho quá trình giảm gradient). Mặc dù hiệu suất này hiện tại cản trở các ứng dụng trực tuyến và tương tác của thuật toán chuyển đổi phong cách của chúng tôi, nhưng có khả năng các cải tiến trong học sâu trong tương lai sẽ tăng cường hiệu suất của phương pháp này.

Một vấn đề khác là các hình ảnh được tổng hợp đôi khi bị nhiễu mức thấp. Mặc dù điều này ít gây vấn đề trong chuyển đổi phong cách nghệ thuật, nhưng vấn đề trở nên rõ ràng hơn khi cả hình ảnh nội dung và phong cách đều là ảnh chụp và tính hiện thực của hình ảnh tổng hợp

bị ảnh hưởng. Tuy nhiên, nhiễu rất đặc trưng và dường như giống với các bộ lọc của các đơn vị trong mạng. Do đó, có thể xây dựng các kỹ thuật khử nhiễu hiệu quả để xử lý hậu kỳ các hình ảnh sau quy trình tối ưu hóa.

Việc tách biệt nội dung và phong cách của một hình ảnh không phải là một vấn đề dễ dàng. Điều này là do phong cách của một hình ảnh có thể được tạo nên bởi nhiều yếu tố khác nhau như: nội dung của một bức tranh, màu sắc, lựa chọn chủ đề phong cách cho hình ảnh,… Vì vậy, không rõ liệu chúng ta có thể hoàn toàn tách biệt nội dung và phong cách của một hình ảnh hay không? Nếu có thể, thì làm thế nào để thực hiện điều đó? Ví dụ, không thể tạo ra một hình ảnh theo phong cách của bức tranh "Đêm đầy sao" của Van Gogh mà không có các lớp cấu trúc hình ảnh giống như các ngôi sao. Trong công việc của chúng tôi, chúng tôi coi việc chuyển đổi phong cách là thành công nếu hình ảnh được tạo ra trông giống như hình ảnh phong cách nhưng vẫn hiển thị các đối tượng và cảnh quan của hình ảnh gốc. Tuy nhiên, chúng tôi nhận thức rằng tiêu chí đánh giá này không chính xác hoàn toàn và không được đồng thuận rộng rãi.

Chúng tôi thấy rất thú vị rằng một hệ thống nơ-ron, được đào tạo để nhận dạng hình ảnh, có thể tự động học cách tách biệt nội dung và phong cách của hình ảnh. Điều này có thể là do khi hệ thống học cách nhận dạng đối tượng, nó phải bỏ qua những thay đổi trong hình ảnh mà vẫn nhận ra được đối tượng đó. Những biểu diễn này giúp phân tích sự khác biệt giữa nội dung và hình thức của hình ảnh, điều này rất hữu ích cho việc nhận dạng. Vì các mạng nơ-ron nhân tạo và mắt của con người có nhiều điểm tương đồng, chúng tôi suy đoán rằng vì con người có khả năng trong việc tách biệt nội dung và phong cách tạo ra, từ đó con người có thể thưởng thức nghệ thuật.

6. Hướng phát triển của VGG19 trong NST

- Tối ưu hóa kiến trúc mô hình:
    - *Giảm số lượng tham số:* Điều chỉnh cấu trúc VGG19 để giảm số lớp hoặc số lượng tham số, nhằm tăng tốc độ xử lý và giảm yêu cầu tài nguyên tính toán.
    - *Sử dụng mô hình nhẹ hơn:* Thay thế VGG19 bằng các mô hình nhẹ như MobileNet hoặc EfficientNet để áp dụng NST trên các thiết bị có khả năng tính toán hạn chế.
- Kết hợp với các mô hình tiên tiến:
    - *ResNet và DenseNet:* Sử dụng các mạng này để cải thiện khả năng trích xuất đặc trưng, nhờ cơ chế kết nối tắt giúp học được các đặc trưng phức tạp hơn.
    - *Transformers:* Áp dụng các mô hình như Vision Transformers (ViT) để nắm bắt mối quan hệ toàn cục trong hình ảnh, nâng cao chất lượng chuyển đổi phong cách.
- Cải thiện hiệu quả thời gian thực:
    - *Mạng học sinh-giáo viên:* Sử dụng VGG19 làm mô hình "giáo viên" để huấn luyện một mạng nhỏ hơn, nhanh hơn, phù hợp cho ứng dụng thời gian thực.
    - *Kỹ thuật tăng tốc:* Áp dụng các phương pháp như cắt tỉa trọng số (pruning) hoặc lượng tử hóa (quantization) để giảm kích thước mô hình và tăng tốc độ xử lý.
- Cải tiến hàm mất mát:

    - *Thêm thành phần ngữ nghĩa:* Kết hợp thông tin ngữ nghĩa để mô hình hiểu rõ hơn mối quan hệ giữa nội dung và phong cách, cải thiện chất lượng hình ảnh đầu ra.
    - *Hàm mất mát có trọng số động:* Điều chỉnh trọng số giữa mất mát nội dung và phong cách trong quá trình huấn luyện để đạt kết quả tốt nhất cho từng trường hợp cụ thể.
- Đa dạng hóa ứng dụng:
    - *Chuyển đổi phong cách video:* Mở rộng từ hình ảnh tĩnh sang video, đảm bảo sự mượt mà và nhất quán giữa các khung hình.
    - *Chuyển đổi phong cách 3D:* Áp dụng NST cho các mô hình 3D hoặc trong lĩnh vực thực tế ảo và tăng cường.
    - *Ứng dụng thực tế tăng cường (AR):* Tối ưu hóa NST để áp dụng phong cách trong các ứng dụng AR thời gian thực.
- Học chuyển giao (Transfer Learning):
    - Sử dụng các đặc trưng học được từ VGG19 để huấn luyện các mô hình cho các nhiệm vụ khác, như nhận dạng đối tượng hoặc phân loại hình ảnh.
- Kết hợp với trí tuệ nhân tạo sáng tạo (Generative AI):
    - Tích hợp NST với các mô hình Generative Adversarial Networks (GANs) để tạo ra hình ảnh có phong cách chân thực và tự nhiên hơn.
    - Sử dụng các công nghệ AI tổng hợp khác để tạo ra các phong cách động hoặc phong cách tùy chỉnh theo người dùng.

7. Tổng kết

Neural Style Transfer (NST) là một phương pháp sáng tạo trong xử lý ảnh, sử dụng mạng nơ-ron tích chập để tách biệt và kết hợp đặc trưng nội dung và phong cách từ hai hình ảnh bất kỳ. Phương pháp này dựa trên việc trích xuất đặc trưng nội dung từ các lớp sâu và đặc trưng phong cách từ các lớp nông của mạng, với sự hỗ trợ của ma trận Gram để mã hóa mối quan hệ giữa các đặc trưng. NST đã chứng minh tiềm năng lớn trong nghệ thuật số và các ứng dụng sáng tạo, mặc dù còn gặp thách thức về hiệu suất, tốc độ và khó khăn trong việc tách biệt hoàn toàn nội dung và phong cách. Với sự phát triển của công nghệ học sâu và phần cứng, NST hứa hẹn sẽ tiếp tục được cải thiện và mở rộng, trở thành một công cụ mạnh mẽ trong cả nghiên cứu và thực tiễn.

Tài liệu tham khảo

1. A Neural Algorithm of Artistic Style, *Leon A. Gatys, Alexander S. Ecker, Matthias Bethge* https://arxiv.org/abs/1508.06576
2. Image Style Transfer Using Convolutional Neural Networks, *Leon A. Gatys, Alexander S. Ecker, Matthias Bethge* https://github.com/superb20/Image-Style-Transfer-Using-Convolutional-Neural-Networks